



Universidade do Estado do Amazonas
Escola Superior de Tecnologia

Comparação de Ferramentas AutoML

FLAML e LightAutoML

Aplicadas ao Dataset de Combustíveis ANP

Disciplina:	Ciência de Dados
Equipe:	9
Ferramentas:	FLAML e LightAutoML
Versão:	3.0
Data:	31 de maio de 2026
Integrantes:	Ana Beatriz Maciel Nunes Fernando Luiz Da Silva Freire Juliana Ballin Lima



Este relatório apresenta o conjunto completo da atividade de comparação de ferramentas AutoML: Parte 1 (teoria), Parte 2 (dataset), Parte 3 (FLAML), Parte 4 (LightAutoML) e Parte 5 (reflexão e comparação), como entrega final da atividade da disciplina de Ciência de Dados na UEA.

© 2026 Equipe 9, Ciência de Dados, UEA. Uso acadêmico.

UEA · Equipe 9 • v3.0

Histórico de Versões

Versão	Data	Autores	Descrição
1.0	26/05/2026	Equipe 9	Criação inicial do relatório. Parte 1: explicação teórica sobre AutoML. Parte 2: descrição do dataset ANP.
2.0	30/05/2026	Equipe 9	Segunda entrega. Parte 3: aplicação da primeira ferramenta AutoML, FLAML, ao problema de regressão do preço médio da gasolina C.
3.0	31/05/2026	Equipe 9	Entrega final. Parte 4: aplicação da segunda ferramenta AutoML, LightAutoML. Parte 5: reflexão crítica e comparação entre as duas ferramentas.

Organização dos relatórios da atividade:

- **v1.0:** Parte 1 - Explicação teórica sobre AutoML; Parte 2 - Descrição do dataset.
- **v2.0:** Parte 3 - Aplicação da primeira ferramenta AutoML (FLAML).
- **v3.0** (este documento): Parte 4 - Aplicação da segunda ferramenta (LightAutoML); Parte 5 - Reflexão e comparação das ferramentas. Inclui também as partes anteriores para completude.

Sumário

Histórico de Versões	1
Resumo Executivo	3
1 Explicação Teórica sobre AutoML	4
1.1 O que é AutoML?	4
1.2 Etapas de ML que podem ser automatizadas	4
1.3 Etapas que ainda dependem da análise humana	5
1.4 Principais vantagens do AutoML	5
1.5 Riscos e limitações do AutoML	5
1.6 AutoML substitui o cientista de dados?	6
2 Descrição do Dataset	7
2.1 Identificação e Fonte	7
2.2 Estrutura dos Dados	8
2.3 Variável-Alvo e Tipo de Problema	8
3 Aplicação da Primeira Ferramenta AutoML: FLAML	9
3.1 Nome e breve descrição	9
3.2 Instalação e principais etapas	9
3.3 Modelos testados e melhor modelo encontrado	9
3.4 Métricas obtidas no conjunto de teste	10
4 Aplicação da Segunda Ferramenta AutoML: LightAutoML	12
4.1 Nome e breve descrição	12
4.2 Instalação e acesso	12
4.3 Preparação para o experimento	12
4.4 Principais comandos e etapas utilizadas	13
4.5 Modelos testados automaticamente	14
4.6 Melhor modelo e métricas obtidas	14
4.7 Recursos gerados pela ferramenta	15
4.8 Importância dos atributos	16
4.9 Análise dos erros no conjunto de teste	17
4.10 Validade experimental da Parte 4	19
4.11 Síntese da aplicação da LightAutoML	19
5 Reflexão e Comparação das Ferramentas	21
5.1 Comparativo de desempenho	21
5.2 Qual ferramenta foi mais fácil de usar?	21
5.3 Qual ferramenta apresentou melhor desempenho?	21
5.4 A ferramenta com melhor desempenho também foi a mais fácil de usar?	22
5.5 Alguma ferramenta gerou explicações sobre os resultados?	22
5.6 O AutoML ajudou a reduzir o tempo de desenvolvimento?	22
5.7 Quais decisões ainda precisaram ser tomadas pela equipe?	22
5.8 Quais problemas poderiam ocorrer sem compreensão de Ciência de Dados?	23
5.9 Em que situações o AutoML pode ser útil em projetos reais?	23
5.10 Em que situações o AutoML pode não ser adequado?	23
5.11 Qual ferramenta a equipe recomendaria para iniciantes?	24
5.12 Encaminhamento final	24
Referências	26

Resumo Executivo

Este relatório consolida a comparação entre **FLAML** e **LightAutoML** na previsão do preço médio mensal da gasolina C por UF, usando o dataset tratado da ANP entre janeiro de 2021 e dezembro de 2025. As duas ferramentas foram avaliadas com a mesma variável-alvo, a mesma divisão treino e teste, a mesma semente aleatória e a mesma métrica principal, RMSE.

Ferramenta	RMSE	MAE	R ²	Tempo
FLAML	0,1148	0,0819	0,9693	60,78s
LightAutoML	0,1134	0,0888	0,9701	73,94s

Tabela 1: Resumo dos principais resultados no conjunto de teste.

Conclusão executiva: as duas ferramentas apresentaram desempenho praticamente equivalente. A LightAutoML teve leve vantagem em RMSE e R², enquanto a FLAML teve melhor MAE, melhor MAPE, menor tempo de execução e maior transparência operacional. Para iniciantes, a recomendação da equipe é a FLAML. Para cenários com necessidade de pipelines mais automatizados e multiníveis, a LightAutoML é uma alternativa robusta.

Principais evidências coletadas:

- Os experimentos foram executados por scripts reproduzíveis em `src/flaml_analysis.py` e `src/lightautoml_analysis.py`.
- As métricas e previsões da FLAML estão registradas nas tabelas de saída do experimento.
- As métricas e previsões da LightAutoML estão registradas nas tabelas de saída do experimento.
- Os gráficos de valores reais contra previstos, importância de atributos e erros regionais estão em `outputs/figures/`.
- As colunas com risco de vazamento de dados foram removidas antes do treinamento nas duas ferramentas.

1 Explicação Teórica sobre AutoML

Esta seção responde às questões teóricas solicitadas na atividade sobre AutoML, com base nos slides disponibilizados na nota da disciplina (<https://classroom.google.com/u/1/c/NzkzOTU2MDI1NjE4>) e com base em pesquisa bibliográfica e compreensão conceitual da equipe.

1.1 O que é AutoML?

AutoML (Automated Machine Learning) é o conjunto de técnicas, ferramentas e processos que automatizam etapas repetitivas e técnicas do ciclo de desenvolvimento de modelos de Machine Learning. O objetivo central é reduzir o esforço manual necessário para construir pipelines de ML de qualidade, desde a preparação dos dados até a seleção e otimização do modelo final.

Diferentemente da abordagem tradicional, em que o cientista de dados realiza manualmente cada escolha do pipeline, como a seleção do algoritmo, o ajuste de hiperparâmetros e a engenharia de atributos, o AutoML executa essas etapas de forma sistemática e automatizada. Isso é possível graças a técnicas como busca em espaço de hiperparâmetros, otimização bayesiana, meta-aprendizado e avaliação cruzada automática.

O AutoML surgiu como resposta à crescente demanda por aplicações de ML em diferentes domínios e à escassez de especialistas com domínio técnico profundo. Ferramentas como FLAML, LightAutoML, AutoGluon, H2O AutoML e PyCaret representam implementações práticas desse conceito, cada uma com diferentes abordagens e focos.

1.2 Etapas de ML que podem ser automatizadas

Diversas etapas do ciclo de Machine Learning podem ser total ou parcialmente automatizadas por ferramentas AutoML:

- **Pré-processamento de dados:** imputação de valores ausentes, normalização e padronização de variáveis numéricas, codificação de variáveis categóricas (one-hot, label encoding) e detecção de tipos de dados.
- **Engenharia de atributos:** criação e transformação de features, seleção automática de atributos relevantes e redução de dimensionalidade.
- **Seleção de algoritmos:** comparação automática entre múltiplos algoritmos de ML (regressão linear, árvores de decisão, gradient boosting, redes neurais, entre outros).
- **Ajuste de hiperparâmetros:** busca automática das melhores configurações de cada modelo por meio de grid search, random search ou otimização bayesiana.
- **Avaliação e validação:** aplicação automática de validação cruzada (cross-validation), cálculo de métricas de desempenho e seleção do melhor modelo com base nos resultados.
- **Ensemble de modelos:** combinação automática de múltiplos modelos para melhorar o desempenho final (stacking, bagging, blending).
- **Geração de relatórios:** criação automática de resumos com métricas, importância de atributos e leaderboards comparativos.

1.3 Etapas que ainda dependem da análise humana

Apesar do alto grau de automação, várias etapas do processo de ML ainda dependem fundamentalmente da análise e julgamento humanos:

- **Definição do problema:** identificar qual pergunta se quer responder, qual é a variável-alvo e que tipo de problema se trata (classificação, regressão, clustering).
- **Coleta e curadoria de dados:** obter, limpar e organizar os dados de forma adequada ao problema. A qualidade dos dados é responsabilidade humana.
- **Definição de métricas de avaliação:** escolher a métrica mais adequada ao contexto do negócio ou da pesquisa.
- **Interpretação dos resultados no contexto do domínio:** entender o significado prático das previsões do modelo e validar se fazem sentido no contexto real.
- **Avaliação ética e de vieses:** identificar e mitigar vieses presentes nos dados ou nos modelos.
- **Validação com especialistas do domínio:** verificar se os resultados são coerentes com o conhecimento especializado da área.
- **Implantação e monitoramento em produção:** decidir como integrar o modelo ao sistema real e como monitorar seu desempenho ao longo do tempo.

1.4 Principais vantagens do AutoML

O uso de ferramentas AutoML traz diversas vantagens práticas e estratégicas:

- **Redução do tempo de desenvolvimento:** o processo que levaria dias ou semanas de experimentação manual pode ser realizado em horas.
- **Democratização do ML:** permite que analistas e pesquisadores utilizem técnicas avançadas sem dominar todos os aspectos matemáticos e computacionais.
- **Exploração sistemática do espaço de modelos:** o AutoML explora combinações de algoritmos e hiperparâmetros de forma mais abrangente do que um humano poderia fazer manualmente.
- **Reprodutibilidade:** o processo automatizado garante que os experimentos possam ser replicados com os mesmos resultados.
- **Redução de erros humanos:** evita descuidos comuns na configuração manual de pipelines, como vazamento de dados e comparação inadequada de modelos.
- **Baseline rápido:** permite obter um modelo de referência de qualidade rapidamente.

1.5 Riscos e limitações do AutoML

O AutoML não é uma solução universal e apresenta riscos e limitações importantes:

- **Interpretabilidade reduzida:** os modelos gerados automaticamente, especialmente ensembles complexos, podem ser difíceis de interpretar.
- **Alto custo computacional:** a busca automática por melhores modelos pode demandar muito tempo e recursos computacionais.

- **Risco de overfitting:** sem uma configuração adequada da validação, os modelos podem se ajustar excessivamente aos dados de treino.
- **Dependência da qualidade dos dados:** o AutoML não corrige problemas fundamentais nos dados de entrada.
- **Caixa-preta:** a automação pode obscurecer as escolhas feitas pelo sistema, dificultando o diagnóstico de problemas.
- **Limitações no domínio do problema:** nem sempre o AutoML encontra o melhor modelo para problemas muito específicos.

1.6 AutoML substitui o cientista de dados?

Não. O AutoML é uma ferramenta que potencializa o trabalho do cientista de dados, mas não o substitui. As razões são diversas:

Em primeiro lugar, o AutoML automatiza tarefas técnicas e repetitivas, mas não é capaz de definir o problema correto, compreender o contexto do negócio, avaliar a qualidade e relevância dos dados nem interpretar os resultados à luz do conhecimento especializado do domínio.

Em segundo lugar, o uso irresponsável de AutoML sem compreensão do processo pode levar a modelos tendenciosos, com vazamento de dados ou com métricas infladas que não refletem o desempenho real.

Em terceiro lugar, a implantação de modelos em produção, o monitoramento de desvios ao longo do tempo e as decisões éticas sobre uso de algoritmos em contextos sensíveis exigem julgamento humano que nenhuma ferramenta automatizada possui.

Conclusão: AutoML é um acelerador poderoso no toolkit do cientista de dados. Ele elimina parte do trabalho repetitivo, permite explorar mais alternativas em menos tempo e facilita a construção de baselines rápidos. Mas o papel do cientista de dados permanece insubstituível nas etapas que exigem julgamento, contexto e responsabilidade.

2 Descrição do Dataset

2.1 Identificação e Fonte

Campo	Informação
Nome	Dataset ANP - Análise de Preços e Volumes de Combustíveis (2021-2025)
Fonte	Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP), bases públicas: Série Histórica do Levantamento de Preços e Vendas de Derivados de Petróleo e Biocombustíveis
Disponibilidade	Público, disponibilizado pela ANP no portal de dados abertos
Período	Janeiro de 2021 a dezembro de 2025
Granularidade	Mensal por Unidade Federativa (UF)
Arquivo processado	data/processed/dataset_anp_pca_mds_2021_2025.csv

O dataset foi construído a partir do cruzamento entre duas bases públicas da ANP: a série histórica de preços médios de revenda de combustíveis e os registros de volume vendido (em m³) de derivados de petróleo e biocombustíveis. O merge foi realizado por mês e sigla de UF, garantindo a inclusão de todas as 27 unidades federativas.

2.2 Estrutura dos Dados

Atributo	Tipo	Descrição
mes_ano	Data	Mês e ano de referência da observação (formato YYYY-MM-01)
uf	Categórico	Sigla da Unidade Federativa (ex.: AM, SP, RJ)
uf_nome	Categórico	Nome completo da UF (ex.: AMAZONAS)
regiao	Categórico	Região geográfica do Brasil (NORTE, NORDESTE, etc.)
ano	Numérico	Ano de referência (2021 a 2025)
mes	Numérico	Mês de referência (1 a 12)
preco_medio_gasolina_c	Numérico	Preço médio mensal de revenda da gasolina C (R\$/litro)
preco_medio_etanol_hidratado	Numérico	Preço médio mensal de revenda do etanol hidratado (R\$/litro)
volume_gasolina_c_m3	Numérico	Volume vendido de gasolina C no mês (em m ³)
volume_etanol_hidratado_m3	Numérico	Volume vendido de etanol hidratado no mês (em m ³)
volume_total_analisado_m3	Numérico	Soma dos volumes de gasolina C e etanol hidratado (em m ³)
participacao_etanol	Numérico	Proporção do etanol no volume total analisado
razao_etanol_gasolina	Numérico	Razão entre volume de etanol e volume de gasolina C
preco_relativo_etanol_gasolina	Numérico	Razão entre preço do etanol e preço da gasolina C
variacao_preco_gasolina_c	Numérico	Variação percentual mensal do preço da gasolina C
variacao_volume_gasolina_c	Numérico	Variação percentual mensal do volume vendido de gasolina C

Dimensões do dataset: 1.619 registros (observações UF-mês) e 16 atributos. O dataset cobre os 27 estados brasileiros ao longo de 60 meses (jan/2021 a dez/2025), resultando em uma cobertura praticamente completa do período analisado.

2.3 Variável-Alvo e Tipo de Problema

Para a atividade de AutoML, a variável-alvo escolhida é `preco_medio_gasolina_c`: preço médio mensal de revenda da gasolina C, em R\$/litro, registrado por UF e mês de referência. O tipo de problema é **regressão**, avaliado pelas métricas RMSE e R².

Divisão treino e teste: 80% para treino e 20% para teste, estratificada por região geográfica, com `random_state = 42` aplicado nas duas ferramentas. Isso gerou 1.295 registros de treino e 324 registros de teste.

3 Aplicação da Primeira Ferramenta AutoML: FLAML

3.1 Nome e breve descrição

A primeira ferramenta aplicada foi a **FLAML** (Fast and Lightweight AutoML), uma biblioteca desenvolvida pela Microsoft voltada à busca eficiente de bons modelos com baixo custo computacional. Seu diferencial está em explorar, de forma automática, candidatos de modelos e combinações de hiperparâmetros dentro de um orçamento de tempo definido, priorizando eficiência sem abrir mão de desempenho competitivo.

3.2 Instalação e principais etapas

A execução foi realizada em ambiente virtual Python local. As dependências foram registradas em `requirements.txt`, incluindo `flaml` e `lightgbm`. O script reprodutível foi implementado em `src/flaml_analysis.py`.

Configuração	Valor
Tipo de problema	Regressão
Variável-alvo	<code>preco_medio_gasolina_c</code>
Métrica principal	RMSE
Divisão dos dados	80% treino e 20% teste
Semente aleatória	42
Orçamento de tempo	60 segundos
Estimadores avaliados	<code>lgbm</code> , <code>rf</code> , <code>extra_tree</code>

3.3 Modelos testados e melhor modelo encontrado

Estimador	RMSE de validação	Selecionado	Observação
<code>lgbm</code>	0,1255	Sim	Melhor equilíbrio entre erro e tempo dentro do orçamento.
<code>extra_tree</code>	0,1287	Não	Resultado próximo ao melhor modelo.
<code>rf</code>	0,2501	Não	Desempenho inferior no orçamento disponível.

O melhor modelo selecionado foi um **LightGBM Regressor** (`lgbm`), com hiperparâmetros ajustados automaticamente incluindo `n_estimators = 1294`, `num_leaves = 22` e `learning_rate = 0,0132`.

3.4 Métricas obtidas no conjunto de teste

Métrica	Valor	Interpretação
RMSE	0,1148	Erro médio quadrático em R\$/litro.
MAE	0,0819	Erro absoluto médio de aproximadamente oito centavos por litro.
R ²	0,9693	O modelo explicou 96,93% da variação observada.
MAPE	1,3841%	Erro percentual médio baixo para o recorte testado.
Tempo de execução	60,78 segundos	Dentro do orçamento definido.




Figura 1: FLAML: comparação entre valores reais e previstos no conjunto de teste.




Figura 2: FLAML: principais atributos do melhor modelo selecionado.

Síntese da Parte 3: a FLAML foi fácil de configurar, superou baselines simples com ampla margem (RMSE reduziu 82,5% em relação à média do treino), selecionou **lgbm** como melhor modelo e gerou métricas, leaderboard, previsões e importância de atributos dentro de 60 segundos.

4 Aplicação da Segunda Ferramenta AutoML: LightAutoML

Objetivo da Parte 4: aplicar a segunda ferramenta AutoML atribuída à equipe, documentar o fluxo experimental com os mesmos critérios adotados na Parte 3 e apresentar os resultados obtidos, preparando a comparação da Parte 5.

4.1 Nome e breve descrição

A segunda ferramenta aplicada foi a **LightAutoML** (LAMA), uma biblioteca de AutoML desenvolvida pelo Sber AI Lab (anteriormente Sberbank). Diferentemente de ferramentas que apenas buscam o melhor estimador único, a LightAutoML foi projetada para construir automaticamente pipelines de múltiplos níveis, incluindo pré-processamento adaptativo, seleção de features, treinamento de modelos base e combinação por blending.

Sua arquitetura interna organiza o processo em níveis hierárquicos: o primeiro nível executa vários modelos base (como modelos lineares, LightGBM e redes neurais para dados tabulares), e os níveis subsequentes combinam as previsões por meio de blending automático. A ferramenta foi originalmente desenvolvida para lidar com problemas de grande escala em serviços financeiros, mas funciona bem em datasets tabulares de porte médio como o utilizado neste experimento.

Entre os diferenciais da LightAutoML em relação à FLAML estão o uso de validação cruzada interna com mais dobras (5 dobras no experimento), a capacidade de inferência automática do tipo de cada variável (numérica, categórica, de data) sem necessidade de pré-processamento manual, e a geração de importância de atributos por meio de gradientes aproximados.

4.2 Instalação e acesso

A LightAutoML foi instalada no mesmo ambiente virtual do projeto, ao lado da FLAML, garantindo que o experimento comparativo fosse realizado no mesmo ambiente de execução.

Etapa	Comando utilizado
Criar ambiente virtual	<code>python -m venv .venv</code>
Ativar ambiente	<code>source .venv/bin/activate</code>
Instalar dependências	<code>pip install -r requirements.txt</code>
Instalar LightAutoML	<code>pip install lightautoml</code>
Executar experimento	<code>python -m src.lightautoml_analysis</code>

O script reproduzível foi implementado em `src/lightautoml_analysis.py`. Ele carrega o mesmo dataset processado, aplica a mesma divisão treino e teste definida na Parte 2, treina a LightAutoML com as configurações descritas abaixo e salva métricas, previsões, importância de atributos e gráficos de apoio.

4.3 Preparação para o experimento

O arquivo utilizado foi `data/processed/dataset_anp_pca_mds_2021_2025.csv`, com 1.619 registros. A mesma divisão da FLAML foi aplicada: 80% para treino (1.295 registros) e 20% para teste (324 registros), com `random_state = 42` e estratificação por região.

As mesmas colunas removidas na etapa da FLAML foram excluídas aqui para garantir comparabilidade:

- `variacao_preco_gasolina_c`: derivada diretamente da variável-alvo.
- `preco_relativo_etanol_gasolina`: razão que usa o preço da gasolina C no denominador.
- `mes_ano`: substituída pelas colunas numéricas `ano` e `mes`.
- `uf_nome`: duplica a informação de `uf`.

A LightAutoML realiza o pré-processamento internamente, identificando automaticamente o tipo de cada coluna. As variáveis categóricas `uf` e `regiao` foram passadas diretamente ao pipeline sem codificação manual prévia, pois a ferramenta aplica a codificação de forma adaptativa durante o treinamento.

Configuração	Valor
Tipo de problema	Regressão (<code>reg</code>)
Variável-alvo	<code>preco_medio_gasolina_c</code>
Métrica interna	MSE (minimização)
Métrica principal de avaliação	RMSE
Divisão dos dados	80% treino e 20% teste
Validação cruzada interna	5 dobras (<code>cv = 5</code>)
Semente aleatória	42
Orçamento de tempo	120 segundos
Limite de CPUs	4

4.4 Principais comandos e etapas utilizadas

As principais etapas executadas no script foram:

1. Carregamento do dataset processado da ANP.
2. Separação da variável-alvo `preco_medio_gasolina_c`.
3. Remoção de colunas que poderiam causar vazamento de dados ou duplicidade.
4. Divisão treino e teste com estratificação por região.
5. Definição da tarefa de regressão com a classe `Task("reg", metric="mse")`.
6. Instanciação do `TabularAutoML` com orçamento de 120 segundos e 5 dobras de validação cruzada.
7. Treinamento automático via `fit_predict()`, que executa internamente a construção do pipeline completo.
8. Predição no conjunto de teste via `predict()`.
9. Cálculo de RMSE, MAE, R^2 e MAPE no conjunto de teste.
10. Extração da importância de atributos via `get_feature_scores("fast")`.
11. Geração de métricas, previsões, análise de erros por região e gráficos.

4.5 Modelos testados automaticamente

A LightAutoML constrói automaticamente um pipeline de múltiplos níveis, sem expor diretamente um leaderboard comparativo de estimadores individuais como a FLAML. No nível base, o pipeline tabular padrão (TabularAutoML) inclui:

- **Modelos lineares regularizados:** utilizados como modelos base de nível 0, com regularização L1 ou L2 definida automaticamente.
- **LightGBM:** gradient boosting baseado em LightGBM, com hiperparâmetros ajustados por busca interna.
- **Combinação por blending:** no segundo nível, as previsões dos modelos base são combinadas por um modelo de blending treinado nas previsões de validação cruzada.

O pipeline final executado dentro do orçamento de 120 segundos incluiu os modelos base lineares e o LightGBM, combinados por blending automático. As previsões fora da amostra (out-of-fold) geradas durante a validação cruzada foram usadas para treinar o blender.

4.6 Melhor modelo e métricas obtidas

O pipeline final gerado pela LightAutoML obteve os seguintes resultados no conjunto de teste, que não foi utilizado em nenhuma etapa do treinamento:

Métrica	Valor	Interpretação
RMSE	0,1134	Erro médio quadrático em R\$/litro.
MAE	0,0888	Erro absoluto médio de aproximadamente nove centavos por litro.
R ²	0,9701	O modelo explicou 97,01% da variação observada no teste.
MAPE	1,4942%	Erro percentual médio para o recorte testado.
Tempo de execução	73,94 segundos	Dentro do orçamento definido de 120s.




Figura 3: LightAutoML: comparação entre valores reais e previstos no conjunto de teste.

Leitura dos resultados: o RMSE de 0,1134 e o R^2 de 0,9701 indicam que o pipeline construído automaticamente pela LightAutoML capturou com boa fidelidade a estrutura dos preços de combustíveis no período analisado. O erro absoluto médio de aproximadamente R\$ 0,09 por litro é baixo para o contexto do problema.

4.7 Recursos gerados pela ferramenta

O experimento gerou os seguintes artefatos no projeto:

Arquivo	Conteúdo
outputs/tables/lightautoml_metricas.csv	Métricas finais no conjunto de teste, tempo de execução e configuração geral.
outputs/tables/lightautoml_importancia_atributos.csv	Importância dos atributos calculada pelo método <code>get_feature_scores("fast")</code> .
outputs/tables/lightautoml_previsoes_teste.csv	Valores reais, previsões e erros no conjunto de teste.
outputs/tables/lightautoml_analise_erros_regiao.csv	Resumo dos erros médios por região no conjunto de teste.
outputs/tables/lightautoml_resumo_erros.csv	Estatísticas resumidas da distribuição dos resíduos.
outputs/figures/lightautoml_real_vs_previsto.png	Gráfico de valores reais contra valores previstos.
outputs/figures/lightautoml_importancia_atributos.png	Gráfico dos principais atributos do pipeline.
outputs/figures/lightautoml_hist_error_absoluto.png	Distribuição dos erros absolutos.
outputs/figures/lightautoml_mae_por_regiao.png	Erro absoluto médio por região.

4.8 Importância dos atributos

A importância dos atributos foi obtida via `get_feature_scores("fast")`, que retorna a contribuição de cada variável para o pipeline treinado. Os dez atributos mais importantes foram:

Rank	Atributo	Importância
1	preco_medio_etanol_hidratado	9.642,29
2	ano	4.613,17
3	participacao_etanol	2.963,76
4	mes	865,96
5	volume_gasolina_c_m3	550,67
6	razao_etanol_gasolina	529,31
7	volume_etanol_hidratado_m3	481,90
8	volume_total_analisado_m3	288,75
9	variacao_volume_gasolina_c	120,22
10	uf	0,00

O atributo mais importante foi o preço do etanol hidratado, o que é esperado dada a forte correlação de mercado entre os dois combustíveis. Em segundo lugar, o atributo **ano** capturou a tendência de alta observada no período de 2021 a 2025. A participação do etanol e o mês de referência completam os quatro atributos de maior peso, refletindo a sazonalidade dos preços e a dinâmica de substituição entre combustíveis.

Um resultado interessante é que as variáveis categóricas **uf** e **regiao** obtiveram importância zero no método rápido de cálculo. Isso pode indicar que, após o controle das variáveis contínuas de preço,

volume e tempo, a variação regional já estava capturada indiretamente pelos demais atributos. Esse comportamento difere da FLAML, em que a codificação one-hot das categorias regionais contribuiu de forma mais explícita para o modelo.




Figura 4: LightAutoML: importância dos atributos no pipeline treinado.

4.9 Análise dos erros no conjunto de teste

A distribuição dos resíduos da LightAutoML no conjunto de teste apresentou as seguintes características:

Resumo do erro	Valor
Mediana do erro absoluto	0,0718
75% dos erros absolutos	0,1276
90% dos erros absolutos	0,1916
95% dos erros absolutos	0,2277
Máximo erro absoluto	0,4180
Desvio-padrão do erro assinado	0,1135
Erro médio assinado	-0,0028

Tabela 2: Resumo da distribuição dos resíduos da LightAutoML no conjunto de teste.

A maior parte das previsões ficou com erro absoluto abaixo de R\$ 0,13 por litro (percentil 75). O erro médio assinado foi praticamente nulo (-0,0028), o que indica ausência de viés sistemático relevante. O maior erro absoluto observado foi de R\$ 0,42, consideravelmente menor do que o máximo da FLAML (R\$ 0,80).

Em nível regional, os erros ficaram distribuídos da seguinte forma:

Região	MAE	RMSE	Erro médi	MAPE
CENTRO OESTE	0,0760	0,0968	0,0120	1,2865%
SUDESTE	0,0848	0,1127	-0,0264	1,4508%
NORDESTE	0,0888	0,1140	-0,0052	1,4807%
NORTE	0,0917	0,1165	0,0186	1,5195%
SUL	0,1048	0,1251	-0,0334	1,8105%

Tabela 3: Erro médio da LightAutoML por região no conjunto de teste.

O Centro-Oeste apresentou o menor erro médio, enquanto o Sul manteve o maior MAE entre as regiões, o mesmo padrão observado na FLAML. Isso sugere que o Sul tem características específicas de preços e volumes que tornam a previsão mais desafiadora independentemente da ferramenta utilizada.




Figura 5: LightAutoML: erro absoluto médio por região.




Figura 6: LightAutoML: distribuição dos erros absolutos no conjunto de teste.

4.10 Validade experimental da Parte 4

Para que a comparação com a FLAML fosse justa, a aplicação da LightAutoML seguiu os mesmos cuidados metodológicos da primeira ferramenta. O conjunto de teste foi mantido isolado até a etapa final de avaliação, a estratificação por região foi preservada e as colunas derivadas diretamente da variável-alvo foram removidas antes do treinamento.

Critério de controle	Como foi aplicado
Mesma base de dados	Uso do arquivo tratado <code>dataset_anp_pca_mds_2021_2025.csv</code> .
Mesma divisão experimental	80% treino e 20% teste, com <code>random_state = 42</code> e estratificação por região.
Mesma variável-alvo	Previsão de <code>preco_medio_gasolina_c</code> .
Mesmo controle de vazamento	Remoção de <code>variacao_preco_gasolina_c</code> e <code>preco_relativo_etanol_gasolina</code> .
Mesma métrica central	RMSE calculado no conjunto de teste.
Reprodutibilidade	Scripts, tabelas e figuras salvos no repositório para auditoria dos resultados.

Mesmo com esses controles, a comparação deve ser interpretada como um experimento didático e exploratório. O orçamento de tempo não foi idêntico porque a LightAutoML precisou de maior folga para completar seu pipeline multinível, enquanto a FLAML foi avaliada com orçamento menor e estimadores explicitamente limitados.

4.11 Síntese da aplicação da LightAutoML

A LightAutoML apresentou desempenho muito próximo ao da FLAML, com RMSE de 0,1134 e R^2 de 0,9701 no conjunto de teste. O pipeline de múltiplos níveis construído automaticamente conseguiu capturar a estrutura dos preços com fidelidade elevada, mantendo erro médio abaixo de R\$ 0,09 por litro.

A configuração exigiu mais etapas de instalação e compreensão da API, mas a ferramenta assumiu automaticamente a responsabilidade pelo pré-processamento, tipo das variáveis e construção do pipeline completo. O tempo de execução foi maior que o da FLAML (73,94s contra 60,78s), mas ainda dentro de um orçamento aceitável.

Síntese da Parte 4: a LightAutoML construiu automaticamente um pipeline de múltiplos níveis com LightGBM e blending, obteve $RMSE = 0,1134$ e $R^2 = 0,9701$ no conjunto de teste, gerou importância de atributos e análise de erros por região, e executou dentro do orçamento de 120 segundos. O atributo mais importante foi o preço do etanol hidratado, seguido pelo ano e pela participação do etanol.

5 Reflexão e Comparação das Ferramentas

Objetivo da Parte 5: responder às questões de reflexão propostas na atividade com base na experiência prática da equipe na aplicação de FLAML e LightAutoML ao dataset de combustíveis ANP.

5.1 Comparativo de desempenho

Antes de responder às questões de reflexão, apresenta-se o comparativo consolidado das métricas obtidas pelas duas ferramentas no mesmo conjunto de teste:

Ferramenta	RMSE	MAE	R ²	MAPE	Tempo (s)
FLAML (lgbm)	0,1148	0,0819	0,9693	1,3841%	60,78
LightAutoML	0,1134	0,0888	0,9701	1,4942%	73,94

Tabela 4: Comparativo de desempenho entre FLAML e LightAutoML no conjunto de teste.

A diferença entre as ferramentas foi pequena em todas as métricas, com vantagem parcial para a LightAutoML em RMSE e R² e para a FLAML em MAE e MAPE. Isso indica que ambas chegaram a soluções de qualidade equivalente para este problema.

5.2 Qual ferramenta foi mais fácil de usar?

A **FLAML** foi consideravelmente mais fácil de usar. Sua API é direta: basta instanciar o `AutoML()`, definir o tipo de tarefa e o orçamento de tempo e chamar `fit()`. O leaderboard comparativo de estimadores fica acessível de forma imediata, o que facilita a compreensão do que aconteceu durante o treinamento.

A LightAutoML exige um nível de compreensão maior da arquitetura da ferramenta. A definição da tarefa usa uma classe própria (`Task`), o método de treinamento é `fit_predict()` em vez do padrão `fit()`, e a extração de importância de atributos requer um passo adicional com `get_feature_scores()`. Além disso, o pipeline interno da LightAutoML não expõe diretamente os modelos avaliados em cada nível, o que dificulta a inspeção do processo por usuários iniciantes.

Por fim, a instalação da LightAutoML gerou avisos relacionados a pacotes opcionais de processamento de linguagem natural não instalados (como `fasttext` e `transformers`), o que pode confundir usuários sem experiência.

5.3 Qual ferramenta apresentou melhor desempenho?

O desempenho foi muito próximo. A **LightAutoML** teve leve vantagem em RMSE (0,1134 contra 0,1148) e em R² (0,9701 contra 0,9693). Por outro lado, a **FLAML** teve melhor MAE (0,0819 contra 0,0888) e melhor MAPE (1,3841% contra 1,4942%). Em termos práticos, a diferença de RMSE foi de apenas 0,0014, o que equivale a menos de R\$ 0,002 por litro.

Considerando a métrica principal adotada na atividade (RMSE), a LightAutoML foi ligeiramente superior. Entretanto, as diferenças observadas são tão pequenas que qualquer variação no conjunto de treino ou nas sementes aleatórias poderia inverter esse resultado. A conclusão mais robusta é que **as duas ferramentas chegaram a soluções de desempenho equivalente para este problema.**

5.4 A ferramenta com melhor desempenho também foi a mais fácil de usar?

Não. A LightAutoML obteve o melhor RMSE, mas a FLAML foi a ferramenta mais fácil de configurar e usar. Esse resultado ilustra um dilema frequente em AutoML: ferramentas com pipelines mais sofisticados e potencialmente mais poderosos tendem a ter curvas de aprendizado mais íngremes. Para este problema específico, a diferença de desempenho não foi suficientemente grande para justificar a complexidade adicional da LightAutoML, especialmente em um contexto de uso inicial ou prototipação rápida.

5.5 Alguma ferramenta gerou explicações sobre os resultados?

Ambas as ferramentas geraram alguma forma de explicabilidade, mas com diferenças:

- **FLAML:** forneceu a importância de atributos baseada no ganho do LightGBM, além de um leaderboard com os estimadores avaliados e os hiperparâmetros do melhor modelo. Essas informações são relativamente fáceis de interpretar.
- **LightAutoML:** forneceu importância de atributos via gradientes aproximados (`get_feature_scores("fast")`), mas não expôs diretamente o processo de seleção dos modelos internos nem os hiperparâmetros ajustados. A ausência de um leaderboard comparativo reduz a transparência do processo.

Nenhuma das duas ferramentas gerou explicações no nível de SHAP ou LIME de forma automática, o que seria necessário para interpretar previsões individuais. A geração de explicações em nível de instância continuou sendo uma etapa humana.

5.6 O AutoML ajudou a reduzir o tempo de desenvolvimento?

Sim, de forma significativa. Sem AutoML, a equipe teria que:

1. Selecionar manualmente os algoritmos candidatos.
2. Definir grades de hiperparâmetros para cada algoritmo.
3. Implementar a busca por validação cruzada.
4. Comparar os resultados e selecionar o melhor modelo.
5. Repetir o processo iterativamente até atingir um desempenho satisfatório.

Com a FLAML, esse processo foi reduzido a menos de 61 segundos de execução. Com a LightAutoML, a menos de 74 segundos. O esforço humano se concentrou na preparação dos dados, na definição do problema e na interpretação dos resultados.

5.7 Quais decisões ainda precisaram ser tomadas pela equipe?

Mesmo com o uso de AutoML, a equipe precisou tomar as seguintes decisões:

- **Escolha do dataset:** selecionar o dataset de combustíveis ANP como base para os experimentos.
- **Definição da variável-alvo:** escolher `preco_medio_gasolina_c` como alvo do problema de regressão.
- **Remoção de colunas com vazamento de dados:** identificar quais atributos deveriam ser excluídos para evitar contaminação do modelo.
- **Definição da métrica principal:** optar por RMSE como métrica central de comparação.

- **Orçamento de tempo:** definir 60 segundos para a FLAML e 120 segundos para a LightAutoML.
- **Interpretação dos resultados:** analisar a importância dos atributos no contexto do mercado de combustíveis.
- **Análise dos erros por região:** avaliar se o desempenho era uniforme entre as cinco regiões brasileiras.

5.8 Quais problemas poderiam ocorrer sem compreensão de Ciência de Dados?

O uso de AutoML sem compreensão dos fundamentos de Ciência de Dados pode gerar problemas sérios:

- **Vazamento de dados:** sem remover as colunas derivadas do alvo, o modelo teria aprendido a usar informações que não estariam disponíveis em produção, gerando métricas artificialmente otimistas.
- **Escolha inadequada da métrica:** usar acurácia em um problema de regressão ou RMSE quando o negócio exige minimizar erros grandes seria um equívoco que o AutoML não detecta automaticamente.
- **Interpretação incorreta dos resultados:** um R^2 de 0,97 pode parecer excelente, mas um usuário sem conhecimento não saberia avaliar se o modelo seria generalizável para dados futuros ou se estava apenas memorizando padrões históricos.
- **Overfitting não detectado:** sem compreender a divisão treino-teste e validação cruzada, o usuário poderia aceitar métricas calculadas sobre dados de treino como resultado final.
- **Implantação irresponsável:** um modelo de previsão de preços aplicado sem monitoramento e sem entendimento das suas limitações poderia gerar decisões prejudiciais em contextos reais.

5.9 Em que situações o AutoML pode ser útil em projetos reais?

O AutoML é especialmente útil quando:

- **Prototipação rápida:** há necessidade de avaliar rapidamente a viabilidade de um problema de ML antes de investir em soluções mais elaboradas.
- **Benchmark de baseline:** o objetivo é estabelecer um ponto de referência inicial para comparar com soluções personalizadas.
- **Dados tabulares bem estruturados:** o problema envolve datasets com estrutura clara, sem necessidade de engenharia de features altamente especializada.
- **Equipes com diferentes perfis técnicos:** quando analistas e especialistas de domínio precisam construir modelos sem depender exclusivamente de cientistas de dados.
- **Projetos com restrição de tempo:** quando há prazos curtos e a qualidade do baseline automático é suficiente para o propósito.

5.10 Em que situações o AutoML pode não ser adequado?

O AutoML pode ser insuficiente ou inadequado quando:

- **Dados não estruturados:** problemas com imagens, texto livre, áudio ou séries temporais

complexas geralmente exigem arquiteturas específicas que as ferramentas AutoML padrão não cobrem bem.

- **Requisitos de interpretabilidade regulatória:** setores como saúde, crédito e seguros exigem que os modelos sejam explicáveis de forma auditável, o que ensembles complexos gerados por AutoML dificilmente atendem.
- **Domínios com lógica de negócio específica:** quando as features mais relevantes dependem de conhecimento profundo do domínio para serem construídas, o AutoML pode não explorar adequadamente o espaço de hipóteses relevantes.
- **Datasets muito grandes:** o custo computacional da busca automática em datasets com dezenas de milhões de registros pode ser proibitivo sem infraestrutura adequada.
- **Problemas de produção críticos:** quando o modelo precisa ser validado, monitorado e explicado em nível de instância para conformidade regulatória.

5.11 Qual ferramenta a equipe recomendaria para iniciantes?

A equipe recomenda a **FLAML** para iniciantes. As razões são:

1. **API intuitiva e próxima ao padrão scikit-learn:** a interface da FLAML é familiar para quem já conhece sklearn, facilitando a curva de aprendizado.
2. **Transparência do processo:** o leaderboard comparativo permite que o usuário entenda quais algoritmos foram avaliados e por que o melhor foi selecionado, algo pedagógico para quem está aprendendo.
3. **Instalação simples:** `pip install flaml` sem dependências conflitantes ou avisos de pacotes opcionais.
4. **Desempenho competitivo:** para datasets tabulares de porte médio, a diferença de desempenho em relação a ferramentas mais complexas é pequena, como demonstrado neste experimento.
5. **Documentação acessível:** a documentação oficial da FLAML é clara e possui exemplos didáticos.

A LightAutoML é recomendada para usuários com maior experiência que desejam pipelines mais sofisticados, especialmente em problemas com datasets financeiros ou corporativos de maior complexidade.

Síntese da Parte 5: as duas ferramentas produziram resultados equivalentes para este problema, com RMSE de 0,1148 (FLAML) e 0,1134 (LightAutoML). A FLAML foi mais fácil de usar, mais transparente e igualmente competitiva. A LightAutoML teve leve vantagem em RMSE e R^2 , mas maior complexidade de uso. Para iniciantes, a equipe recomenda a FLAML. Para projetos com maior exigência de sofisticação e pipeline automatizado de múltiplos níveis, a LightAutoML é uma opção mais robusta.

5.12 Encaminhamento final

Como encaminhamento, a equipe entende que o AutoML cumpriu bem o papel de acelerar a construção de modelos fortes para dados tabulares. O experimento também mostrou que comparar ferramentas apenas pela menor métrica pode ser insuficiente: facilidade de uso, interpretabilidade,

custo computacional, documentação e clareza do pipeline são critérios tão importantes quanto pequenas diferenças numéricas.

Em um projeto real, o próximo passo seria validar os modelos em uma janela temporal posterior, acompanhar a estabilidade dos erros por UF e região, e produzir explicações locais das previsões para casos de maior impacto. Assim, o AutoML seria usado como base técnica inicial, mas a decisão final continuaria apoiada por validação humana e conhecimento do domínio de combustíveis.

Referências

- ANP. *Série histórica do levantamento de preços de combustíveis*. Agência Nacional do Petróleo, Gás Natural e Biocombustíveis. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/serie-historica-do-levantamento-de-precos>
- ANP. *Vendas de derivados de petróleo e biocombustíveis por UF*. Disponível em: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/vendas-de-derivados-de-petroleo-e-biocombustiveis>
- HUTTER, F.; KOTTHOFF, L.; VANSCHOREN, J. (eds.). *Automated Machine Learning: Methods, Systems, Challenges*. Springer, 2019.
- LI, Y.; JIANG, T.; ZHANG, S. et al. *FLAML: A Fast and Lightweight AutoML Library*. Proceedings of MLSys, 2021.
- VAKHRUSHEV, A.; RYZHKOV, A.; RYABININ, M. et al. *LightAutoML: AutoML Solution for a Large Financial Services Ecosystem*. arXiv:2109.01528, 2021.
- SCIKIT-LEARN. *Documentação oficial*. Disponível em: <https://scikit-learn.org>