

Comparação de Ferramentas AutoML: FLAML e LightAutoML

Aplicadas ao conjunto de dados de combustíveis ANP (2021-2025)

Disciplina: Ciência de Dados



Equipe



Ana Beatriz

Sistemas de
Informação



Fernando Luiz

Sistemas de
Informação



Juliana Ballin

Sistemas de
Informação



O que é AutoML?

AutoML automatiza etapas repetitivas do ciclo de ML, reduzindo o esforço manual na construção de pipelines de qualidade.

Etapas automatizadas:

- Pré-processamento e codificação de variáveis
- Seleção de algoritmos
- Ajuste de hiperparâmetros
- Validação cruzada e seleção do melhor modelo
- Ensemble de modelos

Etapas que ainda dependem do humano:

- Definição do problema e da variável-alvo
- Coleta e curadoria dos dados
- Avaliação ética e de vieses
- Interpretação no contexto do domínio

AutoML substitui o cientista de dados?

PARTE 1

Resposta: Não.

Por que não:

1. Nenhuma ferramenta define o problema correto sozinha
2. Dados ruins produzem modelos ruins, independentemente da ferramenta
3. Métricas altas sem interpretação podem gerar decisões erradas
4. Implantação em produção, monitoramento e decisões éticas exigem julgamento humano



O Conjunto de Dados

PARTE 2



Nome: Dataset ANP - Preços e Volumes de Combustíveis (2021-2025)

Fonte: Agência Nacional do Petróleo, Gás Natural e Biocombustíveis (ANP) - dados abertos

Estrutura:

- 1.619 registros (UF-mês)
- 16 atributos
- 26 estados brasileiros + Distrito Federal
- 60 meses (jan/2021 a dez/2025)



O Conjunto de Dados




Variável-alvo: 'preco_medio_gasolina_c' (preço médio mensal em R\$/litro)

Tipo de problema: Regressão

Qualidade dos dados:

- Sem valores ausentes
- Variáveis categóricas: 'uf' (27 categorias), 'regiao' (5 categorias)
- Outlier conhecido: São Paulo (volume muito maior que outros estados)



O Conjunto de Dados



Divisão treino-teste: 80% treino (1.295 registros) / 20% teste (324 registros), estratificada por região, com '`random_state = 42`'.

Evidência coletada: arquivo tratado

'`data/processed/dataset_anp_pca_mds_2021_2025.csv`', com 1.619 linhas e 16 colunas, sem valores ausentes.

mes_ano	uf	preco_medio_etanol_hidratado	preco_medio_gasolina_c	volume_etanol_hidratado_m3	volume_gasolina_c_m3	uf_nome	regiao	vol
2021-01-01	AC	4.051	5.229	682.353	10958.7	ACRE	NORTE	116
2021-02-01	AC	4.192	5.52	688.676	9112.5	ACRE	NORTE	980
2021-03-01	AC	4.869	6.121	783.804	10632.7	ACRE	NORTE	114
2021-04-01	AC	5.101	6.228	661.899	10251.0	ACRE	NORTE	109
2021-05-01	AC	5.158	6.319	662.783	11422.6	ACRE	NORTE	120
2021-06-01	AC	5.464	6.361	578.337	11712.8	ACRE	NORTE	122
2021-07-01	AC	5.477	6.381	504.325	12518.0	ACRE	NORTE	130
2021-08-01	AC	5.517	6.431	536.741	12655.5	ACRE	NORTE	131
2021-09-01	AC	5.683	6.493	476.773	12676.5	ACRE	NORTE	131
2021-10-01	AC	5.771	6.667	510.314	12308.8	ACRE	NORTE	131



FLAML - Configuração e Processo

Ferramenta: FLAML (Fast and Lightweight AutoML) - Microsoft

Como foi utilizado:

```
pip install flaml lightgbm  
python -m src.flaml_analysis
```

Configuração:

- Tipo: Regressão
- Métrica: RMSE
- Orçamento de tempo: 60 segundos
- Semente aleatória: 42

FLAML - Configuração e Processo

Estimadores avaliados automaticamente:

Estimador	RMSE de validação	Selecionado?
'lgbm'	0,1255	Sim
'extra_tree'	0,1287	Não
'rf'	0,2501	Não

Melhor modelo: LightGBM com

'n_estimators = 1294',
'num_leaves = 22' e
'learning_rate = 0,0132'.

FLAML - Configuração e Processo

Evidência coletada:

'outputs/tables/flaml_configuracao.json'.

```
outputs > tables > {} flaml_configuracao.json > ...
1  {
2    "best_estimator": "lgbm",
3    "best_config": {
4      "n_estimators": 1294,
5      "num_leaves": 22,
6      "min_child_samples": 9,
7      "learning_rate": 0.01317914306760124,
8      "log_max_bin": 9,
9      "colsample_bytree": 0.5934246909053076,
10     "reg_alpha": 0.03352761119277088,
11     "reg_lambda": 0.05965156855614909
12   }
```

```
13   "best_loss": 0.1254968072607307,
14   "estimator_list": [
15     "lgbm",
16     "rf",
17     "extra_tree"
18   ],
19   "time_budget_seconds": 60,
20   "random_state": 42,
21   "test_size": 0.2,
22   "target": "preco_medio_gasolina_c",
23   "removed_columns": [
24     "preco_medio_gasolina_c",
25     "mes_ano",
26     "uf_nome",
27     "variacao_preco_gasolina_c",
28     "preco_relativo_etanol_gasolina"
29   ]
```


Evidência coletada: 'outputs/tables/flaml_leaderboard.csv'

Estimador	Melhor_loss_validacao_rmse	Melhor_configuracao	Selecionado_como_melhor
lgbm	0.13	("colsample_bytree": 0.5934246909053076, "learning_rate": 0.01317914306760124, "log_max_bin": 9, "min_child_samples": 9, "num_leaves": 22, "reg_alpha": 0.03352761119277088, "reg_lambda": 0.05965156855614909)	True
rf	0.25	("max_features": 0.5651079297892542, "max_leaves": 30, "n_estimators": 5)	False
extra_tree	0.13	("max_features": 0.8100273423683397, "max_leaves": 646, "n_estimators": 218)	False

FLAML - Resultados


Métricas no conjunto de teste:

RMSE: 0,1148; MAE: 0,0819; R^2 : 0,9693; MAPE: 1,3841%; Tempo: 60,78 segundos;



Comparação com baselines simples


- Baseline pela média do treino: RMSE = 0,6553
- FLAML reduziu o RMSE em 82,5% em relação à média do treino



Interpretação: o modelo explicou 96,93% da variação do preço da gasolina C.

FLAML - Importância de Atributos

Principais atributos identificados pelo LightGBM:



Interpretação: o preço do etanol é o principal preditor do preço da gasolina C, o que reflete a dinâmica de competição entre os dois combustíveis no mercado brasileiro.

Erros por região:

- Menores: Centro-Oeste (MAE 0,069) e Sudeste (MAE 0,070)
- Maior: Sul (MAE 0,101)

LightAutoML - Configuração e Processo

PARTE 3

× × × × ×
× × × × ×

Ferramenta: LightAutoML (LAMA) - Sberbank AI Lab / AutoML community

Como foi utilizado:

```
pip install lightautoml  
python -m src.lightautoml_analysis
```

Configuração:

- Tipo: Regressão
- Métrica: MSE (internamente) → avaliado com RMSE
- Validação cruzada: 5 folds
- Orçamento de tempo: 120 segundos

LightAutoML - Configuração e Processo

PARTE 3



Estimadores avaliados automaticamente:

Estimador	RMSE de validação	Selecionado?
lgbm (LightGBM)	0,1134	Sim
catboost	0,1298	Não
linear_l2	0,3156	Não

Melhor modelo: LightGBM (lgbm) via pipeline LAMA
com CV 5 folds - menor RMSE de validação.

LightAutoML - Configuração e Processo

PARTE 3



Evidência coletada:

'outputs/tables/lightautoml_metricas.csv'

lightautoml_metricas.csv			
Ferramenta	Tipo_problema	Variavel_alvo	Metrica_principal
LightAutoML	regressão	preco_medio_gasolina_c	RMSE

Rmse_teste	Mae_teste	R2_teste	Mape_teste_percentual
0.11	0.09	0.97	1.49

Tempo_execucao_segundos	Time_budget_segundos	Registros_treino
73.94	120	1295

Registros_teste	Random_state	Test_size
324	42	0.2

Evidência coletada:

'outputs/tables/lightautoml_importancia_atributos.csv'.



lightautoml_importancia_atributos.csv		
Feature		Importance
preco_medio_etanol_hidratado		9642.29
ano		4613.17
participacao_etanol		2963.76
mes		865.96
volume_gasolina_c_m3		550.67
razao_etanol_gasolina		529.31
volume_etanol_hidratado_m3		481.9
volume_total_analisado_m3		288.75
variacao_volume_gasolina_c		120.22
uf		0
regiao		0

LightAutoML - Resultados Obtidos

PARTE 3

Métricas no conjunto de teste:

RMSE: 0,1145 | MAE: 0,0897 | R^2 : 0,9695 | MAPE: 1,5084% | Tempo: 91,75 segundos



Comparação com baselines simples



- FLAML (lgbm): RMSE 0,1148 | LightAutoML: RMSE 0,1145
- Ferramentas praticamente empatadas no RMSE;
- LightAutoML com R^2 marginalmente maior

Interpretação: o LightAutoML explicou 96,95% da variação do preço ($R^2=0,9695$), com erro médio de R\$0,090/litro e sem viés sistemático (erro médio assinado: -0,003).

LightAutoML - Importância de Atributos

PARTE 3

Principais atributos identificados pelo LightAutoML (LightGBM interno):



Interpretação: o preço do etanol hidratado liderou (importância 9.642) - mais que o dobro do segundo atributo (ano: 4.613). Confirma a mesma dinâmica de competição entre combustíveis identificada pela FLAML.



Erros por região:

- Menores: Centro-Oeste (MAE 0,076) e Sudeste (MAE 0,087)
- Maior: Sul (MAE 0,109) | Norte (MAE 0,093)

Comparação FLAML vs LightAutoML

PARTE 3

Métricas comparativas no conjunto de teste:



Diferença de desempenho

- **FLAML:** RMSE 0,1148 | R^2 0,9693 | MAE 0,0819 | MAPE 1,38% | Tempo ~61s
- **LightAutoML:** RMSE 0,1145 | R^2 0,9695 | MAE 0,0897 | MAPE 1,51% | Tempo ~92s
- RMSE praticamente empatado; FLAML com MAE menor e execução 33% mais rápida

Conclusão: Ambas superaram os baselines simples em ~82% (RMSE baseline ~0,65). RMSE praticamente igual. FLAML foi mais rápida e com menor MAE. LightAutoML teve R^2 marginalmente superior. Empate técnico.

Conclusões



Síntese da comparação das ferramentas AutoML:

Critério	FLAML	LightAutoML
Melhor modelo	LightGBM (lgbm)	LightGBM via LAMA
RMSE no teste	0,1148	0,1145
Tempo de execução	~61 segundos	~92 segundos

Conclusão geral: **RMSE** praticamente igual (0,1148 vs 0,1145). **FLAML:** MAE menor (0,082 vs 0,090) e 33% mais rápida. **LightAutoML:** R^2 marginalmente superior. Ambas superam baselines em ~82%.

Recomendação: prefira **FLAML** quando **velocidade** e MAE forem prioritários; prefira **LightAutoML** quando **R^2** e **pipeline automático** completo forem o critério principal.



Ciência dos Dados

Obrigado (a)!

Grupo 9

AutoML: FLAML e LightAutoML

